

# Estimação por Intervalo

Luan Fiorentin

UFPR - DEST

2019-05-08

- 1 Introdução
- 2 Intervalos de Confiança para a Média:  $\sigma$  Conhecido
- 3 Dimensionamento de Amostra
- 4 Intervalos de Confiança para a Média:  $\sigma$  Desconhecido
- 5 Dimensionamento de Amostra

# Introdução

- Existem dois tipos de **estimativas** que pode-se obter a partir de uma amostra aleatória:
  - Estimativa **pontual**: fornecem como estimativa um único valor numérico para o parâmetro de interesse.
  - Estimativa **intervalar**: fornece um intervalo de valores “plausíveis” para o parâmetro de interesse.
- Por serem **variáveis aleatórias**, os estimadores pontuais possuem uma **distribuição de probabilidade** (distribuições amostrais).

- Pode-se apresentar uma estimativa mais informativa para o parâmetro de interesse, que inclua uma medida de precisão do valor obtido: **estimativa intervalar** ou **intervalo de confiança**.
- Os intervalos de confiança são obtidos a partir da distribuição amostral de seus estimadores.
  - Por exemplo: é possível obter um intervalo de confiança para a média amostral.

# Intervalos de Confiança para a Média: $\sigma$ Conhecido

## Pressuposição inicial:

- A amostra é uma **amostra aleatória simples** (AAS).  
Portanto, todas as amostras de mesmo tamanho tem a mesma probabilidade de serem selecionadas.
- O valor do desvio padrão populacional  $\sigma$  é **conhecido**.
- Uma ou ambas das seguintes condições são satisfeitas:
  - A população é normalmente distribuída.
  - A amostra possui  $n > 30$ .

## Erro amostral:

- Quando coleta-se uma amostra aleatória e calcula-se uma média, o valor da média possui um **desvio natural** em relação ao verdadeiro valor da média populacional (**erro amostral**), ou seja:

$$e = \bar{X} - \mu$$

$$\bar{X} = \mu + e.$$

- Sabe-se que a distribuição amostral da média é uma **distribuição normal**, com média  $\mu$  e variância  $\sigma^2/n$ :

$$\bar{X} \sim N\left(\mu, \frac{\sigma^2}{n}\right).$$



## Margem de erro:

- Usando a transformação

$$Z = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} = \frac{e}{\sigma/\sqrt{n}} \sim N(0, 1),$$

pode-se determinar o erro máximo provável que assumimos para a média amostral que estamos calculando.

- O erro máximo provável ou margem de erro da média é definido por

$$e = z_{\gamma/2} \cdot \frac{\sigma}{\sqrt{n}},$$

onde  $z_{\gamma/2}$  é chamado de **valor crítico**.

## Intervalo de confiança:

- Fixando um valor  $\gamma$  tal que  $0 < \gamma < 1$ , podemos encontrar um valor  $z_{\gamma/2}$  tal que:

$$P[|Z| < z_{\gamma/2}] = \gamma$$

$$P[-z_{\gamma/2} < Z < z_{\gamma/2}] = \gamma$$

$$P\left[-z_{\gamma/2} < \frac{\bar{x} - \mu}{\sigma/\sqrt{n}} < z_{\gamma/2}\right] = \gamma$$

$$P\left[\bar{x} - z_{\gamma/2}\left(\frac{\sigma}{\sqrt{n}}\right) < \mu < \bar{x} + z_{\gamma/2}\left(\frac{\sigma}{\sqrt{n}}\right)\right] = \gamma$$

$$P[\bar{x} - e < \mu < \bar{x} + e] = \gamma$$

- O valor crítico  $z_{\gamma/2}$  é que determina um intervalo possível para o parâmetro de interesse.




Figura 1: Distribuição normal padronizada.

- A área  $\gamma$  representa o **coeficiente de confiança** associado ao **intervalo de confiança** que está sendo construído.
- O valor  $z_{\gamma/2}$  pode ser obtido da tabela da **Normal Padrão**, localizando o valor de  $\gamma/2$  obtido na tabela e determinando o valor  $z_{\gamma/2}$  nas margens.

Exemplo: considere o coeficiente de confiança  $\gamma = 0.95$ :

- Tem-se que  $\gamma/2 = 0.475$  é a área a ser procurada na tabela.
- $\gamma/2 = 0.475 \Rightarrow 1.96$  é o valor crítico.

## Construção do intervalo de confiança:

- Podemos construir um intervalo de confiança com um coeficiente de confiança:

$$IC[\mu, \gamma] = \left[ \bar{X} - z_{\gamma/2} \cdot \left( \frac{\sigma}{\sqrt{n}} \right); \bar{X} + z_{\gamma/2} \cdot \left( \frac{\sigma}{\sqrt{n}} \right) \right]$$

$$IC[\mu, \gamma] = [\bar{X} - e; \bar{X} + e] = \bar{x} \pm e$$

$$\bar{x} - e < \mu < \bar{x} + e.$$

## Como construir um intervalo de confiança???

- Verifique se as suposições são satisfeitas:
  - É uma amostra aleatória.
  - Desvio padrão é conhecido.
  - População tem distribuição normal ou  $n > 30$ .
- Determinar o nível de confiança  $\gamma$ , e o valor crítico  $z_{\gamma/2}$ .
- Determinar a margem de erro  $e$ .
- Calcular o  $IC[\mu, \gamma]$ .

## Interpretação do intervalo de confiança:

Suponha que obtivemos um intervalo de 95% de confiança:

$$IC[\mu, 0.95] = [95; 105]$$

### INTERPRETAÇÃO 1

Nós temos 95% de confiança que a verdadeira média  $\mu$  se encontra entre 95 a 105.

### INTERPRETAÇÃO 2

Nós temos 95% de confiança de que o intervalo entre 95 a 105 contém a verdadeira média populacional  $\mu$ .

## Interpretação do intervalo de confiança:

Suponha que obtivemos um intervalo de 95% de confiança:

$$IC[\mu, 0.95] = [95; 105]$$

### INTERPRETAÇÃO 1 - ERRADA

Nós temos 95% de confiança que a verdadeira média  $\mu$  se encontra entre 95 a 105.

### INTERPRETAÇÃO 2 - CORRETA

Nós temos 95% de confiança de que o intervalo entre 95 a 105 contém a verdadeira média populacional  $\mu$ .



## Confidence intervals based on z distribution




Figura 2: Intervalos de confiança.

## Exercício 1

Uma empresa de computadores deseja estimar o tempo médio de horas semanais que as pessoas utilizam o computador. Uma amostra aleatória de 25 pessoas apresentou um tempo médio de uso de 22,4 horas. Com base em estudos anteriores, a empresa assume que  $\sigma = 5,2$  horas, e que os tempos são normalmente distribuídos.

Construa um intervalo de confiança para a média  $\mu$  com coeficiente de confiança de 95%.

## Exercício 1

$$IC[\mu, \gamma] = \left[ \bar{X} - z_{\gamma/2} \cdot \left( \frac{\sigma}{\sqrt{n}} \right); \bar{X} + z_{\gamma/2} \cdot \left( \frac{\sigma}{\sqrt{n}} \right) \right]$$

$$IC[\mu, \gamma] = \left[ \bar{22},4 - 1,96 \cdot \left( \frac{5,2}{\sqrt{25}} \right); \bar{22},4 + 1,96 \cdot \left( \frac{5,2}{\sqrt{25}} \right) \right]$$

$$IC[\mu, \gamma] = \left[ 22,4 - 2,04; 22,4 + 2,04 \right]$$

$$IC[\mu, \gamma] = 20,36 < \mu < 24,44$$

$$IC[\mu, \gamma] = [20,36; 24,44]$$

## Amplitude do intervalo:

- A **amplitude** de um intervalo de confiança é dada pela diferença entre o limite superior e inferior, ou seja,

$$AMP_{IC} = \left[ \bar{x} - z_{\gamma/2} \cdot \left( \frac{\sigma}{\sqrt{n}} \right) \right] - \left[ \bar{x} + z_{\gamma/2} \cdot \left( \frac{\sigma}{\sqrt{n}} \right) \right]$$

$$AMP_{IC} = 2 \cdot z_{\gamma/2} \cdot \frac{\sigma}{\sqrt{n}}.$$

$$AMP_{IC} = 2 \cdot z_{\gamma/2} \cdot \frac{\sigma}{\sqrt{n}}$$

- $z_{\gamma/2}$ : cada vez que aumenta-se a confiança  $\gamma$ , o valor de  $z_{\gamma/2}$  fica maior e, conseqüentemente, a amplitude do intervalo aumenta.
- $\sigma$ : um grande desvio padrão indica a possibilidade de um considerável distanciamento dos valores amostrais em relação à média populacional.
- $n$ : quanto maior for o tamanho da amostra, maior será a quantidade de informação disponível. Com isso, valores maiores de  $n$  produzem intervalos mais informativos.

## Exercício 2

Seja  $X \sim N(\mu, 36)$ .

- ❶ Para uma amostra de tamanho 50, obtivemos média amostral 18,5. Construa intervalos de confiança de: i) 90%; ii) 95%; e iii) 99%.
- ❷ Calcule as amplitudes dos intervalos acima e explique a diferença.
- ❸ Para um nível de confiança de 95%, construa intervalos de confiança (admita a mesma média amostral 18,5) supondo tamanhos de amostra de: i) 15; e ii) 100.
- ❹ Calcule as amplitudes dos intervalos acima e explique a diferença.

# Dimensionamento de Amostra

- O objetivo do estudo é **estimar a média populacional  $\mu$  desconhecida**. Logo, a pergunta é:

Quantos elementos (itens, objetos, pessoas, ...) eu devo amostrar?

- **Em geral, recomenda-se inicialmente  $n > 30$  como um tamanho de amostra mínimo para grande parte dos problemas.**
- No entanto, pode-se obter uma **estimativa mais adequada** de quantos elementos amostrar.



- A partir do **erro máximo provável**

$$e = z_{\gamma/2} \cdot \frac{\sigma}{\sqrt{n}},$$

pode-se isolar  $n$  e determinar uma **expressão** para estimar o tamanho amostral

$$n = \left[ \frac{z_{\gamma/2} \cdot \sigma}{e} \right]^2.$$

- Tamanho da amostra  $n$  não depende do tamanho da população  $N$ .
- No entanto, o **tamanho amostral** depende do:
  - Nível de confiança desejado ( $\gamma$ ).
  - Erro máximo desejado ( $e$ ).
  - Desvio padrão ( $\sigma$ ).

$$n = \left[ \frac{z_{\gamma/2} \cdot \sigma}{e} \right]^2$$

- O tamanho amostral precisa ser um **número inteiro**, arredonda-se sempre o valor para o maior número inteiro mais próximo.

### Exercício 3

Desejamos coletar uma amostra de uma variável aleatória  $X$ , com distribuição Normal, de média desconhecida e variância 30. Qual deve ser o tamanho da amostra para que, com 95% de probabilidade, a média amostral não difira da média populacional por mais de 1 unidade? E por mais de 4 unidades?

# Intervalos de Confiança para a Média: $\sigma$ Desconhecido

- Na maioria das situações práticas, não sabemos o **verdadeiro** valor do desvio padrão populacional  $\sigma$ .
- Se o desvio padrão é desconhecido, ele precisa ser estimado.
- Considere variáveis aleatórias  $(X_1, X_2, \dots, X_n)$ , onde  $X \sim N(\mu, \sigma^2)$ , sabe-se que o “melhor” estimador para  $\sigma^2$  é a variância amostral

$$S^2 = \frac{1}{n-1} \left( \sum_{i=1}^n x_i^2 - n\bar{x}^2 \right),$$

a qual não é viciada e é consistente para  $\sigma^2$ .

- A variável padronizada é

$$T = \frac{\bar{X} - \mu}{\sqrt{S^2/n}} = \frac{\bar{X} - \mu}{S\sqrt{n}}.$$

Logo, o denominador  $S^2$  fará com que  $T$  seja diferente da Normal.

- Essa densidade é denominada **t de Student**, e seu parâmetro é denominado **graus de liberdade**, que nesse caso é  $n - 1$ .  
Portanto,

$$T = \frac{\bar{X} - \mu}{S\sqrt{n}} \sim t_{(n-1)}.$$

## Características da distribuição $t$ :

- É **simétrica** com média  $t = 0$  (assim como  $z = 0$ ).
- É **diferente** para tamanhos de amostra diferentes.
- Maior área nas caudas e menor área no centro, quando comparada com a distribuição normal, serve para incorporar as **incertezas**.
- **Desvio padrão** da distribuição  $t$  varia com o tamanho da amostra (ao contrário da distribuição  $z$  onde  $\sigma = 1$ ):
  - Se  $n$  diminui,  $\sigma$  aumenta.
  - Se  $n$  aumenta,  $\sigma$  diminui.
- A medida que o  $n$  amostral aumenta, a distribuição  $t$  se aproxima cada vez mais de uma **distribuição normal padrão  $Z$** .




Figura 3: Distribuição  $t$  de Student.



## Como encontrar os valores críticos de $t$ ?

- Com a definição do **nível de confiança** e sabendo o **tamanho da amostra**  $n$ , sabe-se então o valor de  $\gamma$  e dos G.L., podendo encontrar o **valor crítico** de  $t_{\gamma/2}$ .
- Exemplo:  $\gamma = 0,95$  e uma amostra de tamanho  $n = 7$ :
  - se  $n = 7$ , o G.L. associado é  $n - 1 = 6$ .
  - Na tabela da distribuição  $t$  de Student procura-se a linha correspondente aos G.L., e coluna correspondente ao valor de  $1 - \gamma = 1 - 0,95 = 0,05 = 5\%$ .
  - Valor de  $t_{\gamma/2}$  será determinado pelos valores correspondentes no corpo da tabela. Nesse caso,  $t_{\gamma/2} = 2,447$  é o valor crítico procurado.




Figura 4: Distribuição  $t$  de Student.

## Construção do intervalo de confiança:

- Podemos construir um intervalo de confiança com um coeficiente de confiança:

$$IC[\mu, \gamma] = \left[ \bar{X} - z_{\gamma/2} \cdot \left( \frac{S}{\sqrt{n}} \right); \bar{X} + z_{\gamma/2} \cdot \left( \frac{S}{\sqrt{n}} \right) \right]$$

$$IC[\mu, \gamma] = [\bar{x} - e; \bar{x} + e] = \bar{x} \pm e$$

$$\bar{x} - e < \mu < \bar{x} + e.$$

## Como construir um intervalo de confiança???

- Verifique se as suposições são satisfeitas:
  - É uma amostra aleatória.
  - Desvio padrão é **estimado**.
  - População tem distribuição normal ou  $n > 30$ .
- Determinar o nível de confiança  $\gamma$ , e o valor crítico  $t_{\gamma/2}$ .
- Determinar a margem de erro  $e = t_{\gamma/2} \cdot (S/\sqrt{n})$ .
- Calcular o  $IC[\mu, \gamma]$ .

## Exercício 4

Em um teste da eficácia do alho na dieta para a redução do colesterol, 51 pessoas foram avaliadas e seus níveis de colesterol foram medidos antes e depois do tratamento. As mudanças nos níveis de colesterol apresentaram média de 0,4 e desvio-padrão de 21.

- 1 Para um nível de confiança de 95%, calcule o intervalo para a verdadeira média das mudanças no nível de colesterol
- 2 O que o intervalo de confiança sugere sobre a eficácia do uso do alho na dieta para a redução do colesterol?
- 3 Resolva o mesmo exemplo supondo que o  $\sigma = s$  é conhecido (usando a distribuição  $Z$ ). Compare os resultados.

# Dimensionamento de Amostra

Se  $\sigma$  é **desconhecido**:

- Estimar o valor de  $\sigma$  com base em estudo preliminar.
- Faça uma amostra piloto e estime o desvio padrão amostral  $s$ , e use-o como uma aproximação para o desvio-padrão populacional  $\sigma$ .
- Use a **regra empírica** da amplitude para dados com distribuição (aproximadamente) Normal:

Como sabemos que em uma distribuição (aproximadamente) normal, aproximadamente 95% dos dados encontram-se a 2 desvios-padrões acima e abaixo da média, temos que

$$4\sigma = (max - min)$$

$$\hat{\sigma} = s = \frac{(max - min)}{4}$$